FICHE 1 : Lissage exponentiel

Sommaire

1. Définition 1
2. Positionnement du lissage exponentiel dans l'analyse des séries temporelles 1
3. Lissage exponentiel simple (SES) 2
   3.1. Hypothèse du modèle 2
   3.2. Modèle 2
   3.3. Implémentation sous R 3
4. Lissage exponentiel double (Méthode de Holt) 3
   4.1. Hypothèse 3
   4.2. Modèle 3
   4.3. Implémentation sous R 3
5. Méthode de Holt-Winters 4
   5.1. Hypothèse 4
   5.2. Modèle : version additive 4
   5.3. Modèle : version multiplicative 4
   5.4. Choix entre additif et multiplicatif 5
   5.5. Implémentation sous R 5
6. Méthodologie complète 5
   6.1. Etape 1 : création et visualisation de la série temporelle 5
   6.2. Etape 2 : choix du modèle 5
   6.3. Etape 3 : estimation automatique 5
   6.4. Etape 4 : évaluation 5

1. Définition

Le lissage exponentiel est méthode empirique de lissage et de prévision des données chronologiques affectées d'aléas. Comme dans la méthode des moyennes mobiles, chaque donnée est lissée successivement en partant de la valeur initiale. Le lissage exponentiel donne aux observations passées un poids décroissant exponentiellement avec leur ancienneté (1).

2. Positionnement du lissage exponentiel dans l'analyse des séries temporelles

Une série temporelle est une suite d'observations dans le temps :

$$X_1, X_2, \dots, X_T$$

L'objectif principal est la prévision des valeurs futures à partir des observations passées (prévoir X_{T+h})

Les grandes étapes d'analyse à partir d'une série temporelle sont :

- Représentation graphique
- Identification de la structure : tendance, saisonnalité

- Choix d'un modèle
- Estimation des paramètres
- Validation et prévision

Le lissage exponentiel appartient aux méthodes de prévision non structurelles, fondées sur une mise à jour récursive pondérée des observations passées. Contrairement aux moyennes mobiles classiques, il attribue un poids exponentiellement décroissant aux observations anciennes (moyenne pondérée des observations passées, où les poids décroissent exponentiellement). Ainsi, plus une observation est récente, plus son poids est important.

Il existe plusieurs méthodes de lissage, chacune adaptée à une structure de la série temporelle. On identifie la structure de la série à l'aide d'une représentation graphique.

Tendance	Saisonnalité	Méthode adaptée
NON	NON	Lissage simple
OUI	NON	Lissage double (Holt)
OUI	OUI	Holt-Winters

3. Lissage exponentiel simple (SES)

3.1. Hypothèse du modèle

Le lissage simple est adapté aux séries temporelles :

- Sans tendance
- Sans saisonnalité
- Fluctuant autour d'un niveau constant

3.2. Modèle

Avec $0 < \alpha < 1$:

$$\hat{X}_T = \alpha X_T + (1-\alpha)\hat{X}_{T-1}$$

Forme développée :

$$\hat{X}_T = \alpha \sum_{j=0}^{T-1} (1-\alpha)^j X_{T-j}$$

On note $\hat{X}_T(h)$la prévision de X_{T+h}.
Le paramètre $h \in \mathbb{N}^*$est appelé horizon de prévision : il représente le nombre de périodes dans le futur que l'on souhaite prévoir (par exemple $h = 1$ pour une prévision à un pas, $h = 12$ pour une prévision à 12 mois). Dans le lissage exponentiel simple, la prévision ne dépend pas de l'horizon h qui est donc égale au niveau estimé à la date T. Soit :

$$\hat{X}_{T+h} = \hat{X}_T$$

- Le paramètre $\alpha \in (0,1)$ contrôle la vitesse d'adaptation du modèle aux nouvelles observations. Si le paramètre α est proche de 1, alors nous avons une forte réactivité aux données récentes C'est-à-dire que le poids donné à l'observation récente X_T est très important, les observations anciennes ont un poids très faible et la prévision réagit fortement aux variations récentes. Si la série change brutalement, le modèle s'adapte rapidement. Mais une valeur trop grande de α peut rendre la prévision instable et trop sensible au bruit.
- Si le paramètre α est proche de 0, alors le poids donné aux observation anciennes est important, la série est fortement lissée et la prévision varie lentement. Ainsi, le modèle filtre les fluctuations aléatoires et produit une courbe très régulière. Mais si la série change réellement de niveau, le modèle prendra du temps à s'adapter.

Le paramètre α doit donc contrôlé le compromis entre réactivité aux nouvelles données et stabilité du modèle. Il est généralement choisi en minimisant l'erreur quadratique de prévision. On évalue la qualité de la prévision en calculant l'erreur quadratique totale de prévision à un pas.

$$SSE(\alpha) = \sum_{t=1}^{T-1} (X_{t+1} - \hat{X}_{t+1}(\alpha))^2$$

Si $SSE(\alpha)$ est petit alors le modèle prédit bien. Si $SSE(\alpha)$ est grand alors le modèle est mal ajusté.
Le SES est la solution asymptotique du problème suivant :

$$\min_{C} \sum_{j=0}^{T-1} (1-\alpha)^j (X_{T-j} - C)^2$$

Il s'agit donc d'un ajustement local d'une constante. En pratique, les logiciels (comme R) estiment automatiquement le meilleur α en minimisant cette erreur.

3.3. Implémentation sous R

```
serie <- ts(data, frequency=12, start=c(2000,1)) # Création de la série temporelle
model_ses <- HoltWinters(serie, beta=FALSE, gamma=FALSE) # Lissage exponentiel simple (SES)
forecast_ses <- predict(model_ses, n.ahead=12) # Prévisions
plot(model_ses) # Visualisation
```

4. Lissage exponentiel double (Méthode de Holt)

4.1. Hypothèse

Le lissage exponentiel double est adapté aux série temporelle :

- Avec tendance
- Sans saisonnalité
- On ajuste localement une droite

4.2. Modèle

On estime :

- Niveau : $b(T)$ représente la valeur moyenne actuelle de la série à la date T, corrigée de la tendance.
- Pente (tendance) : $a(T)$ représente la vitesse d'évolution de la série à la date T, c'est-à-dire l'augmentation (ou diminution) moyenne par période.

La prévision à horizon h est obtenue en prolongeant la tendance estimée à la date T, c'est-à-dire en ajoutant h fois la pente actuelle au niveau estimé :

$$\hat{X}_{T+h} = b(T) + ha(T)$$

Avec :

- $b(T) = \alpha X_T + (1-\alpha)\big(b(T-1) + a(T-1)\big)$
- $a(T) = \gamma(b(T) - b(T-1)) + (1-\gamma)a(T-1)$
- $0 < \alpha\,;\, \gamma < 1$ (contrôlent respectivement la rapidité d'adaptation du niveau et de la tendance aux nouvelles informations) : α contrôle l'actualisation du niveau. Plus α est grand, plus le niveau s'adapte rapidement aux nouvelles observations. γ contrôle l'actualisation de la tendance. Plus γ est grand, plus la pente estimée réagit fortement aux variations récentes.

4.3. Implémentation sous R

```
serie <- ts(data, frequency=12, start=c(2000,1)) # Création de la série temporelle
model_holt <- HoltWinters(serie, gamma=FALSE) # Lissage exponentiel double (Méthode Holt)
```

```
forecast_holt <- predict(model_holt, n.ahead=12) # Prévision
plot(model_holt) # Visualisation
```

5. Méthode de Holt-Winters

5.1. Hypothèse

Le modèle de Holt-Winters est adapté aux séries temporelles :

- Avec tendance
- Avec saisonnalité

On décompose la série en :

- Niveau $b(T)$
- Tendance $a(T)$
- Saisonnalité $s(T)$

Il existe deux versions :

- Additive
- Multiplicative

5.2. Modèle : version additive

Forme du modèle :

$$X_t = \text{Niveau} + \text{Tendance} + \text{Saisonnalité} + \varepsilon_t$$

On suppose que l'effet saisonnier s'ajoute de manière constante au niveau de la série. Autrement dit, la hauteur des variations saisonnières ne dépend pas du niveau de la série.

La prévision combine le niveau actuel, la tendance projetée à horizon $h$et la composante saisonnière correspondante :

$$\hat{X}_{T+h} = b(T) + ha(T) + s_{T+h-k}$$

Avec :

- $b(T) = \alpha(X_T - s_{T-k}) + (1-\alpha)\big(b(T-1) + a(T-1)\big)$ (saisonnier à l'observation actuelle pour estimer le vrai niveau, puis combiner cette information avec la prévision précédente)
- $a(T) = \gamma\big(b(T) - b(T-1)\big) + (1-\gamma)a(T-1)$ (pente mise à jour en fonction de l'évolution récente du niveau)
- $s_T = \delta(X_T - b(T)) + (1-\delta)s_{T-k}$ (écart entre l'observation et le niveau actuel)

5.3. Modèle : version multiplicative

Forme du modèle :

$$X_t = (Niveau + Tendance) \times Saison + \varepsilon_t$$

On suppose que l'effet saisonnier est proportionnel au niveau de la série. Autrement dit, plus la série augmente, plus l'amplitude saisonnière augmente.
Pour la prévision, on projette la tendance puis on applique l'effet saisonnier multiplicatif :

$$\hat{X}_{T+h} = (b(T) + ha(T)) \times s_{T+h-k}$$

Avec :

- $b(T) = \alpha\frac{X_T}{s_{T-k}} + (1-\alpha)(b(T-1) + a(T-1))$ (observation divisée par la saison pour retirer l'effet proportionnel avant d'estimer le niveau)
- $a(T) = \gamma(b(T) - b(T-1)) + (1-\gamma)a(T-1)$ (identique au modèle additif : on ajuste la pente selon l'évolution récente)

- $s_T = \delta \frac{X_T}{b(T)} + (1-\delta) s_{T-k}$ (la composante saisonnière est estimée comme un coefficient multiplicatif)

5.4. Choix entre additif et multiplicatif

On choisit le modèle additif lorsque (1) l'amplitude des variations saisonnières reste constante dans le temps, (2) les écarts entre saisons ne grandissent pas avec le niveau.

Exemple : la série oscille toujours d'environ ±10 unités, même si la moyenne augmente.

On choisit le modèle multiplicatif lorsque (1) l'amplitude saisonnière augmente avec le niveau, (2) les pics saisonniers deviennent plus grands quand la série croît.

Exemple : les ventes augmentent chaque année et les pics de décembre deviennent de plus en plus élevés.

5.5. Implémentation sous R

```
serie <- ts(data, frequency=12, start=c(2000,1)) # Création de la série temporelle
########## Modèle additif ##########
model_hw_add <- HoltWinters(serie, seasonal="additive") # Holt-Winters additif
forecast_add <- predict(model_hw_add, n.ahead=12) # Prévisions
plot(model_hw_add) # Visualisation
########## Modèle multiplicatif ##########
model_hw_mul <- HoltWinters(serie, seasonal="multiplicative") # Holt-Winters multiplicatif
forecast_mul <- predict(model_hw_mul, n.ahead=12) # Prévisions
plot(model_hw_mul) # Visualisation
```

6. Méthodologie complète

6.1. Etape 1 : création et visualisation de la série temporelle

```
serie <- ts(data, frequency=12, start=c(2000,1)) # Création de la série temporelle
plot.ts(serie) # Visualisation de la série temporelle
acf(serie) # Identifier la dépendance entre séries et données
```

Le but est d'identifier la tendance, la saisonnalité et la stabilité de la variance.

6.2. Etape 2 : choix du modèle

- Série stable : SES
- Tendance : lissage double (Holt)
- Tendance + saisonnalité : Holt-Winters

6.3. Etape 3 : estimation automatique

La fonction HoltWinters() intégré dans R, permet de minimiser automatiquement la somme des carrés des erreurs. Elle va permettre de modéliser la série.

6.4. Etape 4 : évaluation

On évalue le modèle en comparant les MSE (erreur quadratique moyenne). Plus la MSE est petite, plus le modèle prédit bien. Et inversement, plus elle est grande, plus les erreurs sont importantes.

```
residus <- serie - fitted(model_ses)[,1] # Calculer les résidus
mse <- mean(residus^2) # Calculer la MSE
```